PHEF: черновик формулы, патентный поиск, план экспериментов, коммерциализация

Дата подготовки: 22 августа 2026
Источник фактов: хендоффы №10–№15 (`~/qubitrino-projects/agi/phef`) и README ablation-отчёта. Все числа ниже взяты оттуда; ничего не додумано.

Не является юридической консультацией. Формула ниже — рабочий черновик для передачи патентному поверенному, а не текст для подачи.

0. Что именно предлагается защищать

Ключевое решение о позиционировании: **защищать не «архитектуру памяти», а способ обучения такой памяти на большом масштабе истории.**

Причины:

- Архитектура key-value памяти с обучаемыми ключами и значениями занята плотно и давно: Large Memory Layers with Product Keys (2019), Memory Layers at Scale (Meta FAIR, 2024, 64 млн ключей и 128 млрд memory-параметров), Titans и MIRAS (Google, 2025). Новизна тут почти наверняка не устоит.
- Патентная территория «внешняя память для нейросети» плотно занята DeepMind: US 12,099,928 B2, US 10,410,119 B2, EP 3295381 B1 и семья US 2017/0228637 A1.
- А вот у вас есть **замеренный технический результат, который прямо влияет на потребление аппаратных ресурсов**: время до выхода из плато сократилось с 22 500 эпох до 250 (хендофф №13), при этом `answer_acc = 1.0`; плюс замеренная экономия VRAM 16 699 → 14 639 MiB от патча `8bdea2f`. Именно такой результат — «улучшение работы вычислительной системы» — является тем, что и Роспатент, и EPO, и USPTO готовы признавать техническим.

То есть: центр тяжести заявки — **сокращение вычислительных затрат**, а память — контекст, в котором это сокращение достигается.

Чего в формулу не писать ни в каком виде

- «Программа», «программное обеспечение», «программный продукт» в родовом понятии — заявку в РФ отклонят на входе (разбор практики Роспатента).
- «Эмерджентная адресация возникает без retrieval-loss» как самостоятельный признак — это наблюдение о поведении математической модели, а не техрешение. В РФ прямо исключено: не считаются техническими результаты, состоящие только в получении информации средствами математического метода (ЭЖ, обзор судебной практики).

- Абстрактное «обучение модели на нескольких задачах/масштабах последовательно» без привязки к ресурсам. Ровно на такой формулировке DeepMind получил отказ по заявке № 16/319,040 — и по очевидности, и дополнительно по §101 как абстрактная идея (обзор решения PTAB). Это самый близкий к вам предупреждающий пример, читать обязательно.

А. Черновик формулы изобретения

А.1. Независимый пункт 1 — способ (основной, версия под РФ)

1. Компьютерно-реализуемый способ обучения модуля ассоциативной памяти вычислительной системы, содержащей процессор и графический ускоритель с ограниченным объёмом видеопамяти, включающий этапы, на которых:

- (а) формируют модуль ассоциативной памяти, содержащий кодировщик ключей, кодировщик запросов, таблицу вложений значений и обучаемые скалярные параметры масштабирования оценки соответствия и масштабирования давности, причём **число обучаемых параметров модуля не зависит от числа обрабатываемых событий N** входного потока;
- (б) на первом этапе обучают указанный модуль на потоке из N_1 событий, каждое из которых содержит ключ и связанное с ним значение, с возможностью перезаписи ранее записанного значения по тому же ключу, при этом функция потерь вычисляется исключительно по предсказанию значения, соответствующего поступившему запросу, и не содержит слагаемого, задающего целевой индекс извлекаемого элемента памяти;
- (в) сохраняют полученный набор весов первого этапа в виде набора тензоров, инвариантного к числу событий N;
- (г) на втором этапе формируют тот же модуль для потока из N_2 событий, где $N_2 \geq 2 \cdot N_1$, и инициализируют его весами, сохранёнными на этапе (в), без изменения размерности тензоров и без введения дополнительных обучаемых параметров;
- (д) продолжают обучение второго этапа на потоке из N_2 событий до достижения заданного порога точности предсказания значения по запросу;

при этом достигаемым техническим результатом является сокращение числа итераций обучения, необходимых для превышения порога точности на потоке из N_2 событий, не менее чем на порядок по сравнению с обучением того же модуля из случайной инициализации, и, как следствие, сокращение времени занятости графического ускорителя и потребляемой электроэнергии при неизменном объёме занимаемой видеопамяти.

Формулировки «не менее чем на порядок» и «$N_2 \geq 2 \cdot N_1$» — плейсхолдеры для торга с экспертизой. Данные позволяют заявить 90× (22 500 → 250) и коэффициент 4 (8192 → 32 768, хендофф №15 §1), но фиксировать в независимом пункте узкие числа невыгодно.

A.2. Зависимые пункты

2. Способ по п. 1, в котором на этапе (г) пропускают промежуточный масштаб, то есть инициализируют модуль для $N_2 = 4 \cdot N_1$ весами, полученными непосредственно на N_1, минуя обучение на $2 \cdot N_1$.
Обоснование: хендофф №15 §1, прыжок 8192 → 32 768 дал `escape 250` и `answer_acc 1.0`, идентично маршруту через 16 384.

3. Способ по п. 1, в котором этапы (в)–(д) повторяют итеративно, формируя цепочку масштабов $N_1 \to N_2 \to \ldots \to N_k$, где каждый последующий превышает предыдущий не менее чем вдвое.
Обоснование: цепочка 8192 → 16 384 → 32 768 → 65 536 → 131 072 подтверждена прогонами.

4. Способ по п. 1, в котором обучение второго этапа выполняют с накоплением градиента по m микропакетам размера B/m, так что эффективный размер пакета сохраняется постоянным при переходе между масштабами N, а произведение размера микропакета на число событий N удерживают ниже порога, определяемого объёмом видеопамяти ускорителя.
Обоснование: §9 хендоффа №15. Помечен как ещё не внесённый патч — на дату подачи должен быть реализован и замерен, иначе пункт не подкреплён.

5. Способ по п. 1, в котором таблицу вложений значений вычисляют без материализации промежуточного тензора в формате одинарной точности, применяя формат пониженной разрядности, чем снижают пиковое потребление видеопамяти.
Обоснование: патч `8bdea2f`, замеренная экономия 16 699 → 14 639 MiB, что совпадает с расчётом для тензора (256, 32768, 128).

6. Способ по п. 1, в котором в процессе обучения с заданной периодичностью формируют промежуточные снимки состояния модуля путём атомарной записи во временный файл с последующей заменой целевого файла, причём формат снимка совпадает с форматом, принимаемым на этапе (г) в качестве инициализирующего.
Обоснование: коммит `517e6b8`; отдельно ценно тем, что снимок совместим с цепочкой — то есть является не просто бэкапом, а входом следующего этапа.

7. Способ по п. 1, в котором на этапе (д) точность оценивают с размером оценочного пакета, выбранным так, что произведение размера оценочного пакета на число событий N не превышает предопределённой константы, зависящей от объёма видеопамяти.
Обоснование: инвариант `eval_batch × N ≈ 8.4e6`, подтверждён дважды (128 × 65 536 и 64 × 131 072, в обоих случаях свободно ровно 2.1 MiB).

8. Способ по п. 1, дополнительно включающий этап контроля, на котором состояния модуля памяти перемешивают между элементами пакета и подтверждают падение точности до уровня случайного угадывания, чем верифицируют, что предсказание получено через канал памяти, а не через остаточный путь.
Обоснование: shuffled-memory probe из README и контроли финального вердикта. Пункт полезен для подкрепления промышленной применимости: способ включает верификацию.

9. Способ по п. 1, в котором ключи событий представляют собой векторы вещественных значений размерности, меньшей размерности скрытого состояния, а соответствие запроса ключам определяют обучаемой метрикой, чем обеспечивают извлечение при неточном совпадении ключа запроса с ключом записи.

10. Способ по любому из пп. 1–9, в котором поток событий формируют из телеметрии программно-аппаратного комплекса, а значения представляют собой классы состояния контролируемого объекта.
Прикладной пункт — важен для ЕРО как «техническое применение».

A.3. Независимый пункт — система

11. Вычислительная система для обучения модуля ассоциативной памяти, содержащая процессор, графический ускоритель и энергонезависимую память, хранящую машиночитаемые инструкции, при исполнении которых система выполняет способ по любому из пп. 1–10, причём система дополнительно содержит модуль контроля объёма видеопамяти, выполненный с возможностью выбора размера микропакета и размера оценочного пакета в зависимости от числа событий N и доступного объёма видеопамяти.

A.4. Независимый пункт — носитель

12. Машиночитаемый носитель, хранящий инструкции, при исполнении которых вычислительная система выполняет способ по любому из пп. 1–10.

Для РФ пункт 12 в такой формулировке рискован; для US/EP «non-transitory computer-readable medium» — стандарт и нужен обязательно.

A.5. Второе изобретение — держать отдельно

Двухступенчатое извлечение (кластеризация N ключей в √N групп, грубый отбор группы, точный поиск внутри) из §7.6/§Приоритет 4 — **отдельная заявка, не зависимый пункт.** Причины: технический результат другой (снижение вычислительной сложности с O(N) до O(√N)), и он прямо конкурирует с product-key lookup, где ровно эта идея разбиения ключевого пространства на два подмножества уже опубликована в 2019 году. Подавать только после того, как `probe_two_stage.py` прочитан и замерен, и только если механизм отличается от произведения кодбуков.

B. Список для патентного и литературного поиска

B.1. Приоритет 1 — риск блокировки формулы п. 1

Документ	Правообладатель	Почему критично
US 11,450,096 B2 — Systems and methods for progressive learning for machine-learned models to optimize training speed	Google	**Самый опасный документ в списке.** Название буквально описывает вашу идею: прогрессивное обучение с целью ускорения. Читать формулу целиком, слово за словом, до любых затрат.

Документ	Правообладатель	Почему критично
US 12,062,227 B2 — то же название, продолжение	Google	Continuation предыдущего; смотреть, куда расширили притязания.
US 11,775,804 B2 — Progressive neural networks	DeepMind	Перенос между задачами, а не между масштабами — но эксперт может привести как аналог.
Заявка US 16/319,040 (отказ PTAB)	DeepMind	Не блокирует, но показывает, как именно отказывают в способах обучения: обзор решения. Использовать как чек-лист «чего не писать».
US 2017/0024641 A1 — Transfer learning in neural networks	Qualcomm	Общий transfer learning; проверить, не покрывает ли «инициализация весами предыдущей конфигурации».

B.2. Приоритет 2 — архитектура памяти (обосновывает отказ от притязаний на архитектуру)

Документ	Правообладатель
US 12,099,928 B2 — Augmented recurrent neural network with external memory	DeepMind
US 10,410,119 B2 — та же семья, ранний член	DeepMind
EP 3295381 B1 — Augmenting neural networks with sparsely-accessed external memory	DeepMind
US 2017/0228637 A1 и US 2017/0323201 A1	Google
US 12,141,692 — Memory-augmented neural network system	—
US 2024/0412054 A1 — Using memory to augment self-attention in neural networks	—
US 12,450,168 B2 — Dynamic updating of content addressable associative memories for LLMs	—
EP 3776369 — Neural networks with relational memory	DeepMind
US 5,253,328 A — Neural-network content-addressable memory, 1989	—

Отдельно: проверить наличие патентных заявок Meta по product-key memory (в поиске всплыли только публикации, патентов не нашлось — это стоит подтвердить, потому что отсутствие патента у Meta означает, что территория свободна, но и что публикация 2019 года работает как убийственное prior art для любых притязаний на архитектуру).

B.3. CPC-классы для сплошного просмотра

`G06N 3/08` (методы обучения), `G06N 3/082` (модификация архитектуры в процессе обучения), `G06N 3/044` (рекуррентные), `G06N 3/063` (аппаратная реализация), `G06N 3/0895`, `G06F 12/0862`. Классы взяты из титульного листа US 12,099,928 B2.

B.4. Поисковые строки

В Espacenet и Google Patents, по формуле и описанию, не только по названию:

1. `(progressive OR curriculum OR staged) AND training AND ("memory module" OR "associative memory") AND ("reduce training time" OR "training speed")`

2. `"initializing" AND "weights" AND ("larger scale" OR "longer sequence") AND "neural memory"`
3. `"key-value memory" AND "gradient accumulation" AND "GPU memory"`
4. `"scale-invariant" AND parameters AND "sequence length" AND "neural network"`
5. `"retrieval loss" AND "key-value" AND "emergent" AND addressing`

B.5. Научное prior art (убивает новизну, если попадёт в отчёт эксперта)

- PKM, Lample et al. 2019 — обучаемые ключи и значения, разбиение ключевого пространства.
- Memory Layers at Scale, Meta FAIR 2024 — 64 млн ключей, 128 млрд memory-параметров.
- Titans и MIRAS — ассоциативная память как явная рамка, память как обучаемая на тесте сеть.
- ARMT — 50 млн токенов на BABILong.
- Литература по MQAR: ревизия associative recall в рекуррентных моделях — там же показано, что современные рекуррентные модели работают только в узких окнах learning rate, что прямо релевантно вашему §7.7.Б.
- Формальная эквивалентность attention и Hopfield-обновления — основной аргумент против новизны «эмерджентной адресации».
- Mixture of Chapters — маршрутизация по «главам» памяти, 262K memory-токенов. Ближайший конкурент вашему двухступенчатому извлечению.

C. План экспериментов для закрытия научных пробелов

Порядок выбран так, чтобы самые дешёвые убийственные проверки шли первыми. Каждый эксперимент имеет критерий, при котором проект останавливается.

C.0. Правило приоритета

Дальше нет ни одной причины идти на 262 144 сегмента. Масштаб больше не является узким местом — узким местом является **отсутствие сравнения с чем-либо.** Все ресурсы GPU до подачи заявки — в E1–E4.

E1. Baseline: attention того же бюджета параметров (блокирующий, ~4 ч)

Зачем. В хендоффах 10–15 нет ни одного сравнения PHEF с альтернативной архитектурой. Без этого утверждение «модуль решает задачу» ничего не стоит: задачу может решать однослойный attention, и тогда весь curriculum-результат — про ускорение обучения вещи, которая не нужна.

Что. Однослойный causal attention с числом параметров, равным PHEF (`dim 128`), на той же задаче: `n_segments` 8192 и 32 768, `overwrite_p 0.3`, `n_values 64`, batch 256, seed 0.

Критерий. Если attention даёт `answer_acc > 0.99` за сопоставимое или меньшее число эпох — **проект как «архитектура памяти» закрыт**, остаётся только патент на способ обучения, и то при условии, что curriculum ускоряет и attention-вариант тоже (тогда изобретение шире и сильнее, что хорошо).
Если attention на уровне chance при 32 768 — у вас есть первый настоящий результат за всю серию, и его надо публиковать/патентовать немедленно.

Замечание по методологии. Attention надо гонять по сетке learning rate минимум из 4 точек. Литература по MQAR прямо показывает, что рекуррентные модели проваливаются вне узкого окна lr — обвинение «вы просто не подобрали lr baseline» снимет вашу работу на любом ревью.

E2. Воспроизводимость curriculum на сидах (блокирующий, ~6 ч параллельно)

Зачем. Прыжок 8192 → 32 768 сделан на одном сиде. Хендофф №12 уже один раз попадал в эту ловушку и сам это зафиксировал.

Что. Сиды 1 и 2, конфигурация §1 №15, `--ckpt-every 10`, два параллельных прогона.

Критерий. `escape 250` и `answer_acc > 0.99` у оба сидов. Провал одного — вывод о прыжке недействителен, п. 2 формулы вычёркивается.

E3. Ablation переноса: что именно переносится (ключевой для формулы, ~12 ч)

Зачем. Формула п. 1 утверждает, что работает перенос обученных весов. Нужно исключить тривиальные объяснения, иначе на экспертизе или на ревью это разберут за минуту.

Три контрольных прогона на 32 768, batch 256, 40k эпох:

Прогон	Инициализация	Что проверяет
E3a	случайные веса, но `score_scale`, `recency_scale`, `memory_gate` установлены в финальные значения прогона 8192	Не сводится ли весь эффект к трём скалярам. Если escape тоже 250 — вместо переноса тензоров достаточно правильной инициализации трёх чисел, формула резко упрощается и **усиливается** (проще обойти сложно).
E3b	веса 8192, но скаляры сброшены в 1.0	Обратная проверка.
E3c	веса, обученные на 8192 со **случайными метками** ответов (модель ничего осмысленного не выучила)	Не является ли эффект просто «любой не-случайной инициализацией». Если escape 250 и здесь — вся гипотеза curriculum ложна.

Критерий. Ожидаемо: E3c проваливается, E3a или E3b дают частичный эффект. Любой другой расклад меняет текст формулы.

E4. Развязка ёмкости и длины истории (~6 ч)

Зачем. Проект называет `n_segments` ёмкостью, но `n_keys 512` и `n_values 64` не менялись ни в одном прогоне. §10 хендоффа №15 это признаёт. Утверждение «взято 131 072» будет прочитано как «ёмкость 131k», чего не измерялось, и это прямая репутационная уязвимость.

Что. При фиксированном `n_segments = 8192` варьировать `n_values` — 64, 256, 1024 — и `n_keys` — 512, 4096. Батч 256 обязательно (проверки при 64 из №11 недействительны).

Критерий. Найти реальную границу по числу различимых ключей и значений. Это и есть настоящая ёмкость, и именно её надо указывать в описании к заявке.

E5. Траектория эталона (§2 №15, ~11 ч)

Повтор эталона 32 768 через 16 384 с `--ckpt-every 10`, чтобы закрыть расхождение `recency_scale` 70.48 против 99.15. Оставить как есть в плане — приоритет ниже E1–E4, но до подачи заявки желательно понимать механизм, потому что «работает, а почему не знаем» плохо переживает вопросы эксперта о промышленной применимости.

E6. Проверка патча накопления градиента (~11 ч, зависит от E2)

Контрольный прогон §9 №15: 32 768, микробатч 128 × 2 против эталона batch 256. Нужен для подкрепления п. 4 формулы. Без него пункт 4 из заявки убрать.

E7. Неточные ключи (~4 ч)

Зачем. Подкрепляет п. 9 формулы и — важнее — определяет, есть ли у решения вообще применение (см. раздел E ниже).

Что. К ключу запроса добавлять гауссов шум с σ от 0 до 0.5 от нормы ключа, замерить деградацию `answer_acc`. Отдельно — запрос ключом, которого не было (проверка отказа от ответа).

Критерий. Если точность держится при σ = 0.2 — решение делает то, чего словарь не умеет, и прикладная ценность появляется. Если рушится при σ = 0.05 — это дифференцируемый hash map, и все прикладные сценарии надо пересматривать.

E8. Задача не-синтетическая (~1 день, после E1)

Перенести модуль на реальный поток: лог заявок или тиковый поток, где ключ — эмбеддинг контекста, значение — класс из 64. Без этого шага заявка получит возражение по промышленной применимости, а покупатель технологии — вопрос «а на моих данных?».

Сводка бюджета

Этап	GPU-часы	Блокирует
E1 baseline attention	~4	всё
E2 сиды	~6	п. 2 формулы
E3 ablation переноса	~12	п. 1 формулы
E4 развязка ёмкости	~6	описание к заявке
E7 неточные ключи	~4	прикладные сценарии
E6 накопление градиента	~11	п. 4 формулы
E5 траектория	~11	понимание механизма
E8 реальные данные	~24	промышленная применимость

Итого около 78 GPU-часов — примерно четверо суток одной 4090. Для сравнения: путь до 1 млн сегментов существующим способом оценён вами в ~650 часов и не приносит ни формулы, ни статьи.

Отдельным пунктом: до начала E1 переключить монитор на 4090 и отключить iGPU в BIOS. Зависание `i915` 22 августа уже стоило прогона, и на 24-часовых прогонах E8 это повторится.

D. Коммерциализация

D.1. Рекомендуемый вариант: не патент и не стартап, а инженерный продукт с закрытым ядром

Честная оценка входных данных: у вас один разработчик, одна 4090, синтетическая задача и ноль сравнений с baseline. Стартап «новая архитектура памяти для LLM» в этих условиях не финансируется и конкурирует с FAIR и Google Research. Патент на архитектуру не пройдёт. Поэтому рекомендуемая последовательность:

Шаг 1 (0–1 мес). Приоритетная заявка на способ, узко.
Подать по разделу A. В РФ — с расчётом на режим, вступающий в силу 1 января 2027, когда поправки в четвёртую часть ГК впервые прямо допускают патентование технических решений, реализуемых исключительно программным способом, включая машинное обучение (ЭЖ, одобрение закона Советом Федерации). Параллельно US provisional — она дешёвая, даёт 12 месяцев и фиксирует дату при том, что EPO требует технической реализации, которая у вас как раз замерена (Guidelines G-II, 3.3.1).
Стоимость ориентировочно: заявка РФ через поверенного — десятки тысяч рублей плюс пошлины; US provisional — несколько сотен долларов пошлины плюс работа поверенного. Это единственные деньги, которые стоит тратить до E1.

Шаг 2 (1–2 мес). E1–E4. До результата E1 никаких других вложений.

Шаг 3 (2–4 мес). Развилка по результату E1.

- **Attention выиграл** → патент на способ остаётся (он всё равно про ускорение обучения памяти, и это применимо к чужим модулям памяти), архитектурная линия закрывается, публикуется статья с отрицательными результатами. Это не провал: серия «как три инфраструктурных дефекта создали иллюзию прорыва, и как batch_size на неделю закрыл настоящую причину» — редкий и цитируемый жанр, и она работает как ваша профессиональная витрина.
- **PHEF выиграл** → идти в Шаг 4.

Шаг 4. Продукт: библиотека `phef` под двойной лицензией.
Ядро — pip-пакет: дифференцируемый модуль ассоциативной памяти + утилита масштабного curriculum-обучения (`fit_scaled(module, from_scale, to_scale)`), которая автоматически подбирает микробатч и оценочный батч под доступную VRAM по замеренным вами инвариантам. Продаваемое обещание конкретно и проверяемо: «обучение модуля памяти на истории в 4 раза длиннее — за 250 эпох вместо 22 500». Модель: AGPL для открытой версии, коммерческая лицензия для встраивания в закрытые продукты. Это стандартный путь для одиночного автора: не требует продаж корпоративного уровня, монетизирует именно тот артефакт, который у вас реально есть, и оставляет патент как страховку от копирования крупным игроком.

Шаг 5. QUBITRINO как канал. У вас уже есть публичное присутствие компании и приватный GitLab. Технология встраивается в собственные проекты (`market_mimic`, `trading-volatility-assistant`, телеметрия СПбМТСБ) как демонстрация — это самый дешёвый способ получить референс-кейс, не имея внешнего клиента.

D.2. Что делать не надо

- Продавать «AGI-память». Слово убивает любую техническую беседу.
- Лицензировать патент до его выдачи и до E1 — нечего показать.
- Публиковать хендоффы. Они содержат всё, включая точную конфигурацию и веса-цепочку, и одна выкладка обнуляет новизну по EPO и РФ.

E. Конкретные применения

Сначала — фильтр применимости, без которого список будет самообманом.

Модуль имеет смысл только там, где выполняются одновременно два условия:

1. **Ключ неточный.** Если ключ — точный идентификатор, задачу решает `dict` за O(1), бесплатно и с гарантией 100%, а не 99.98%. Тогда нейросетевая память — проигрыш по всем параметрам.
2. **Извлечение должно быть дифференцируемым**, то есть память стоит внутри обучаемой модели, и градиент должен через неё течь.

Всё, что не проходит этот фильтр, из списка вычеркнуто. Отсюда следует, что E7 (неточные ключи) — не второстепенный эксперимент, а тот, который определяет, существует ли применение вообще.

E.1. Внутри `market_mimic`: память режимов по непрерывному ключу

Ключ — вектор контекста бара (не идентификатор): нормированная волатильность, время внутри сессии, положение относительно уровня, спред. Значение — один из 64 классов последующей реакции. Поток — 130k баров M5, что примерно 4,5 года GBPUSD. Запрос — текущий контекст, который **никогда точно не совпадал ни с одним прошлым**. Словарь тут неприменим в принципе, kNN по 130k векторам на каждом шаге генерации — дорого и недифференцируемо. Модуль отдаёт «что происходило в похожих контекстах» одним матричным произведением и обучается вместе с генератором. Проверяемая метрика: улучшение log-loss условного прогноза t-EDM при добавлении памяти против той же модели без памяти, param-matched. Это ровно та постановка, которую вы уже умеете делать корректно.

E.2. Внутри `trading-volatility-assistant`: последний исход по нечёткому уровню

Ключ — (инструмент, нормированное расстояние до уровня, время суток). Значение — класс исхода следующего часа. `overwrite_p` соответствует реальности: исход по «тому же» уровню перезаписывается при повторном подходе.
Конкретная выгода перед текущим сканером: не нужно вручную задавать бины по уровням и времени — метрика близости обучается, и близкие, но не идентичные ситуации попадают в один слот сами.

E.3. Телеметрия СПбМТСБ: классификация задержки по контексту запроса

Ключ — вектор признаков запроса к терминалу (тип операции, размер payload, загрузка канала, время). Значение — класс задержки из 64 бакетов. Поток — сотни тысяч событий за сессию.
Что даёт: предсказание «этот запрос попадёт в хвост задержек» до его отправки, на основании похожих, а не идентичных прошлых запросов. Дифференцируемость нужна, потому что признаковый кодировщик обучается вместе с памятью.

E.4. RCA по логам: «что уже случалось с похожей ошибкой»

Ключ — эмбеддинг строки лога или трейсбека. Значение — класс первопричины из фиксированного набора (у вас он фактически уже есть: OOM в backward, OOM в analyze, зависание i915, буферизация пайпа, битый JSON). Поток — все логи проекта.
Ровно тот случай, где grep бесполезен, потому что новый трейсбек не совпадает со старым текстуально. И ровно тот случай, где `dict` не работает по определению.

E.5. Дифференцируемый слой «последнее известное состояние» в моделях с перезаписью

Обобщённо: любой ML-контур, где вход — поток событий с перезаписью по нечёткому ключу, а модель обучается end-to-end. Конкретные постановки, где это не абстракция: скоринг устройства по потоку сессий с меняющимся отпечатком (отпечаток дрейфует, точного ключа нет); предсказание отказа узла по потоку метрик, где «тот же узел» после переконфигурации имеет другой вектор признаков; персонализация по эмбеддингу пользователя, который меняется между сессиями.

E.6. Отдельно от архитектуры: сам способ обучения как продукт

Не требует, чтобы PHEF победил attention. Любая команда, обучающая модуль памяти с параметризацией, инвариантной к длине истории, получает от вашего способа сокращение GPU-часов. Это применимо к PKM-слоям и к memory-слоям в стиле Meta — там параметры тоже не зависят от длины обрабатываемой последовательности. Именно поэтому раздел A написан вокруг способа: у него рынок шире, чем у самой архитектуры, и он не умирает от результата E1.

F. Что сделать на этой неделе

1. Прочитать формулу US 11,450,096 B2 целиком. Это решение «идти дальше или нет».
2. Не публиковать ничего. Проверить, что GitLab закрыт, а хендоффы не уходят во внешние сервисы.
3. Отключить iGPU, чтобы `i915` не убил суточные прогоны.
4. Запустить E1. Четыре часа GPU против недель гипотез.
5. Разослать раздел A двум патентным поверенным по IT-профилю, запросить оценку по п. 1 и по риску от US 11,450,096.